

Clasificación de imágenes mediante Vision Transformer (ViT-Base): una aplicación al dataset Caltech 101

*Alexandra González Bermúdez, Emily Estefanía Mora Contreras, Daniela Prado Vargas, Liz de
María Salazar Amaya, Erika Wu Liang*


Introducción: motivación y objetivo



- Este proyecto aplica un modelo preentrenado de clasificación de imágenes, conectando su desempeño con la fundamentación matemática de las bitácoras.
- **Relevancia actuarial:** la confianza de una predicción permite distinguir casos automatizables de casos que requieren revisión humana (ej. reclamos o daños en seguros).

Tarea seleccionada y justificación

- **Tarea:** clasificación de imágenes.
- **Modelo:** ViT-Base (Vision Transformer, patch16-224), vía Transformers.
- **Por qué:** adapta la atención de los Transformers (NLP) al análisis visual, útil para segmentación y predicción de riesgos en la actuaría.



Descripción del dataset

- **Fuente:** Caltech 101 (Li, Andreetto, Ranzato & Perona, 2022)¹: cerca de **9.000 imágenes**, **101 categorías**.
- Entre 40 y 800 imágenes por clase.
- Imágenes de **~300×200 px**, objetos centrados y fondos simples.



inline_skate (51)



crab (23)



llama (58)



crocodile_head (26)



beaver (7)



sea_horse (83)



faces (37)



mandolin (61)

¹Li, F., Andreetto, M., Ranzato, M. & Perona, P. (2022). *Caltech 101 (1.0)* [Data set]. CaltechDATA. <https://doi.org/10.22002/D1.20086>

Descripción del modelo y metodología

- Redimensiona la imagen a 224×224 px y la divide en **196 parches** de 16×16 px.
- Cada parche se convierte en un vector numérico (embedding) mediante una proyección lineal.
- Se incorpora información de posición para preservar la disposición espacial de los parches.
- El mecanismo de **atención** permite que cada parche intercambie información con los demás.
- El token **[CLS]** concentra la información de toda la imagen y produce las probabilidades finales.
- **Metodología:** modelo aplicado sin fine-tuning sobre las primeras 100 imágenes de Caltech-101.

Fundamentación matemática: relación con las Bitácoras 1 y 2

- **Multiplicación matricial + capa lineal** ($Y=XW+b$): convierte cada parche en un embedding.
- **Broadcasting**: suma la información posicional a cada embedding.
- **Producto punto + softmax**: mecanismo de atención entre parches.
- **Layer Normalization**: normalización independiente por parche.
- **Conexiones residuales**: suma elemento a elemento alrededor de cada bloque.
- **Softmax final**: produce la probabilidad por categoría (confianza).

Resultados: distribución de confianza




Figure 1: Distribución de confianza del modelo ViT-Base aplicado al dataset Caltech-101.

Resultados: predicciones con mayor confianza

Clase real	Predicción del modelo	Confianza
nautilus	chambered nautilus, pearly nautilus	0.999
trilobite	trilobite	0.999
accordion	accordion, piano accordion	0.999
binocular	binoculars, field glasses	0.999
flamingo_head	flamingo	0.999
flamingo	flamingo	0.998
scorpion	scorpion	0.998
revolver	revolver, six-gun	0.998
beaver	beaver	0.997
airplanes	airliner	0.997

Resultados: predicciones con menor confianza

Clase real	Predicción del modelo	Confianza
pigeon	black grouse	0.024
gramophone	loudspeaker, speaker unit	0.042
faces	Windsor tie	0.065
yin_yang	puck, hockey puck	0.067
motorbikes	crash helmet	0.079
yin_yang	nematode, nematode worm	0.081
rhino	African elephant	0.082
joshua_tree	screen, CRT screen	0.082
helicopter	lakeside, lakeshore	0.089
stapler	harmonica, mouth organ	0.092

Resultados: predicciones más frecuentes

Predicción del modelo	Frecuencia
disk brake, disc brake	9
airliner	6
stopwatch, stop watch	4
cheetah, Acinonyx jubatus	3
triceratops	3
warplane, military plane	2
jaguar, Panthera onca	2
beach wagon, station wagon	2
candle, taper, wax light	2
oboe, hautboy	2

Conclusiones y aplicación actuarial

- Hallazgo: el modelo distingue bien clases con patrones visuales distintivos, pero falla en clases visualmente similares o poco representadas.
- Limitación: baja coincidencia exacta (7%) pese a confianza moderada-alta; indicativo de error en las asignaciones de grados de confianza.
- Aplicación actuarial: apoyo en el análisis de fotos de reclamos/daños en seguros generales, la confianza como criterio para automatizar vs. derivar a revisión humana.